



AWS SUMMIT MÉXICO • SESIÓN DE DATA

Datos listos para IA

Lakehouse, gobierno y seguridad para que tus agentes
no toquen la base de producción.



Lakehouse



Ingesta



Governance



Seguridad

3 horas • charla con casos reales

Quiénes somos

Los que vamos a estar con ustedes estas tres horas



Somos una consultora de Cloud y DevOps nacida en Córdoba, Argentina, en 2020. Trabajamos sobre AWS con equipos propios y acompañamos a las empresas en su infraestructura, su plataforma de datos y, desde hace un par de años, sus agentes de IA.

2020

Desde entonces,
sobre AWS

180+

Proyectos entregados
en 12 países

100%

Del equipo técnico
certificado en AWS

- Oficinas en Córdoba y La Plata, y equipo distribuido por LatAm
- Primera empresa de LatAm en el programa EKS Service Delivery de AWS
- Top Partner 2024 de AWS Startups LatAm • Great Place to Work 2023 y 2024



El 80% de los proyectos de IA no falla por el modelo

Falla por los datos. Y se nota en tres preguntas que casi nadie puede responder.



¿De dónde salió este dato?

El agente respondió un número. ¿De qué sistema viene, quién lo transformó y cuándo se actualizó por última vez?



¿Quién puede verlo?

¿El agente está leyendo columnas con datos personales? ¿Puede un cliente ver, por error, información de otro?



¿Está bien?

¿Alguien validó ese dato? ¿Qué pasa si el equipo de la aplicación cambia una columna sin avisar?

Si no podés responder las tres, tu problema no es de IA: es de plataforma de datos.

Qué vamos a ver

3 horas, cinco bloques



El anti-patrón

qué pasa cuando el agente le pega a la base productiva



Arquitectura medallón

bronze, silver y gold sobre S3 e Iceberg, capa por capa



Ingesta

batch, CDC, zero-ETL, streaming y datos no estructurados



Governance

catálogo, linaje, calidad y contratos de datos



Seguridad

permisos de grano fino, PII, cifrado y residencia de datos


01

El anti-patrón

Conectar el agente directo a la base de producción. Es rápido, funciona en el demo y es una bomba de tiempo.

La arquitectura que todos hacen primero

Y por qué funciona perfecto... en el demo



1

Queries sin plan

Joins sin índice y escaneos completos sobre tablas de millones de filas.

2

Contención

Compite por CPU y por locks con las operaciones que atienden a clientes.

3

Gasto impredecible

Una consulta que redacta un modelo en el momento no se puede presupuestar.

El demo usa una tabla de prueba con mil filas. Producción tiene doscientos millones y un cierre contable en curso.

Lo que se rompe y no se ve

Los tres problemas que aparecen cuando ya es caro arreglarlos



Datos personales sin filtrar

El esquema productivo tiene teléfonos, documentos y direcciones. Nadie los enmascaró: son columnas de la aplicación. El agente los lee y los repite.



Trazabilidad cero

No hay linaje ni registro de qué consultó el agente. Cuando alguien pregunta de dónde salió un número, la respuesta honesta es «no sabemos».



El modelo no ayuda

El esquema transaccional está normalizado para escribir rápido, no para responder preguntas. Nombres crípticos y tablas puente que ni el equipo recuerda.

Ninguno de los tres se arregla con un prompt mejor. Se arreglan antes, en la capa de datos.

Y hay un cuarto, silencioso: el agente que responde bien hoy responde distinto mañana, porque el dato de abajo cambió y nadie avisó.

Dos modelos distintos, dos trabajos distintos

Pedirle a la base transaccional que responda preguntas es pedirle lo que no fue diseñada para hacer

Base transaccional (OLTP)

Optimizada para escribir muchas veces

Normalizada: joins por todos lados

Nombres técnicos de la aplicación

Escalar cuesta y afecta al servicio

Sin historia: guarda el estado actual

Capa analítica (lakehouse)

Optimizada para leer y agregar

Desnormalizada por dominio de negocio

Nombres de negocio, con diccionario

Escala por separado, sin tocar producción

Con historia: podés reproducir el pasado

No es que una sea mejor: es que hacen cosas distintas. La IA necesita la de la derecha.

La alternativa

Una capa analítica gobernada como única fuente para la IA



Producción, intacta

La réplica no compite con el tráfico de clientes.

El costo es acotado

Un almacén pensado para consultar, con presupuesto propio.

El acceso es explícito

Rol con permisos sobre columnas concretas de gold.

Todo queda registrado

Linaje del dato y auditoría de cada lectura.

El resto de la charla es cómo se construye esa cadena del medio.

02

Arquitectura medallón

Bronze, silver y gold. Tres capas con reglas distintas, y una sola que ve la IA.

Por qué lakehouse

Ni data warehouse clásico ni un lago sin reglas



Data warehouse clásico

Estructurado y confiable, pero cerrado y caro para datos crudos o no estructurados. Cargar todo antes de saber si sirve no escala en costo.



Data lake sin reglas

Barato y flexible, y termina en un pantano: archivos sin esquema, sin dueño y sin nadie que sepa cuál es la versión buena.



Lakehouse

El almacenamiento barato de S3 con las garantías de una base: esquema, transacciones e historia. Una copia sirve a BI, a la app y a la IA.

La diferencia entre un lago y un pantano no es la tecnología: son las reglas que le pusiste al escribir.

Las tres capas

Cada una con una regla que no se negocia

BRONZE

Tal como llegó

Copia fiel del origen, inmutable y particionada.
Con metadatos: de dónde vino, cuándo y en qué corrida.

Regla: bronze no se corrige. Si algo está mal, se reprocesa desde acá.

SILVER

Conformado

Limpieza, deduplicación, tipos y claves estandarizadas. Acá se enmascaran los datos personales y se aplican las reglas de calidad.

Regla: nace el modelo de entidades del negocio.

GOLD

Listo para consumir

Agregados y vistas orientadas a preguntas de negocio, ya con semántica.

Regla: es la única capa que ven los usuarios y la IA. Nadie consume silver ni bronze directamente.

Servicios: S3 para las tres capas • Glue ETL o EMR para las transformaciones • Athena, Redshift o SageMaker Lakehouse para consultar.

De archivos sueltos a una tabla con historial

Dónde entra Iceberg, y qué hace S3 Tables que Iceberg solo no hace

Quién pregunta



Athena



Redshift



EMR



Iceberg el formato de tabla

Metadata guardada al lado de los datos: dice qué archivos forman la tabla hoy, y cómo estaba hace un mes.

S3 Tables el mismo piso, pero el mantenimiento lo hace AWS



Amazon S3

Los archivos Parquet. Para S3 son objetos sueltos, no una tabla.



Lo que Iceberg le suma

- Time travel: cómo estaba la tabla el día que el agente respondió.
- Nadie lee una tabla a medio escribir mientras corre la carga.
- Se agregan o renombran columnas sin reescribirla entera.

Sin esta capa, «con qué datos respondió el agente el 12 de marzo» es una pregunta sin respuesta.

El agente no puede levantar la mano y preguntar

Una persona pregunta qué significa una columna. El modelo se lo inventa.

La tabla tal como salió de la aplicación

```
cli_id  
flg_st_2  
dt_cre  
mto_tot
```

¿Qué estado es el «2»? ¿El monto lleva impuestos?

La misma tabla, preparada para que la lea

```
cliente  
estado_del_pedido  
fecha_de_compra  
monto_total_con_iva
```

Cada nombre dice lo que contiene.



Una definición de cada número

«Venta neta» se calcula en un solo lugar y todos los agentes usan ese.



Solo lo que necesita ver

Se le muestran las tablas de su caso de uso, no el esquema entero.



El diccionario, adentro

Las descripciones viajan con la tabla y llegan al agente como contexto.

Regla simple: si una persona nueva tendría que preguntar qué significa algo, el agente lo va a adivinar.


03

Ingesta

Cómo llegan los datos al lakehouse sin castigar a los sistemas que están dando servicio.

Batch y CDC

Las dos formas que resuelven el 90% de los casos



Batch — AWS Glue

Cargas programadas: por noche, por hora o al cerrar un proceso.

- Glue Jobs para transformar, crawlers para descubrir esquemas
- Step Functions para orquestar dependencias
- Reprocesable: si algo sale mal, se corre desde bronze

Es lo más simple y lo que casi siempre alcanza.



CDC — AWS DMS

Replica los cambios leyendo el log, sin consultar la base.


- Impacto mínimo sobre el sistema que da servicio
- Los datos llegan con minutos de retraso, no días
- Reemplaza al agente conectado a producción

Si te llevás una sola cosa técnica, que sea esta.

CDC convierte «el agente lee producción» en «el agente lee una copia gobernada de producción».

Zero-ETL

Los pedidos viven en Aurora y los querés cruzar en Redshift: activás la integración y la tabla aparece del otro lado.



Cuándo conviene

El par ya está en la lista — Aurora, RDS o DynamoDB hacia Redshift o S3 — y el dato puede viajar tal cual, sin transformar en el camino.

Cuándo no

El origen no está soportado — un SQL Server on-prem se resuelve con DMS — o hay que limpiar el dato antes de que llegue al destino.

Antes de construir un pipeline, fijate si AWS ya lo mantiene por vos.

Streaming

Una compra sospechosa hay que frenarla en segundos, no en el batch de la noche.



Data Streams procesa en vuelo · **Firehose** solo deposita en S3 · **MSK** si el equipo ya usa Kafka

Cuándo conviene

La decisión se toma en segundos: frenar una compra sospechosa, reaccionar a telemetría, ajustar un precio en vivo.

Cuándo no

El reporte que se mira mañana a la mañana: un batch por hora entrega lo mismo a una fracción del costo.

La pregunta no es si podés hacerlo en tiempo real: ¿Alguien va a tomar una decisión distinta por tener el dato 55 minutos antes?

SaaS y terceros

Las oportunidades de venta viven en el CRM y las querés en el lakehouse, sin escribir código.



Cuándo conviene

El origen tiene conector: CRM, marketing, mesa de ayuda. AppFlow ya lo tiene hecho; queda elegir campos y frecuencia.

Cuándo no

No hay conector: la API propia se consulta con una Lambda programada y los archivos que llegan por SFTP van directo al bucket.

No importa por dónde entre: todo aterriza en bronze igual, tal cual vino.

Una factura entra, una fila sale

Bedrock Data Automation convierte el documento en un registro consultable

El documento como llega

FACTURA A-0001-4482

12/03/2026

Proveedor: Distribuidora Norte

Total: \$ 184.300



Bedrock Data Automation

lee el documento y devuelve campos

La fila como queda

numero	fecha	proveedor	total
--------	-------	-----------	-------

A-0001-4482	12/03/2026	Distribuidora Norte	\$ 184.300
-------------	------------	---------------------	------------

origen: s3://bronze/facturas/a-0001-4482.pdf

Tipada, filtrable y con SQL: una fila más del lakehouse.

El PDF queda guardado en S3; lo que se consulta es la fila.

Preguntale a la tabla, no al PDF

La misma pregunta, respondida por los dos caminos



Orquestación y calidad

Qué hacer con el dato que no cumple las reglas



Orquestación

Step Functions o MWAA: dependencias explícitas, reintentos y visibilidad de qué falló



Reglas de calidad

Glue Data Quality: completitud, unicidad, rangos y referencias válidas por dataset



Cuarentena, no descarte

Lo que no pasa se aparta y se registra: descartar en silencio es la peor opción



Alertas con dueño

Cada dataset tiene un responsable que se entera antes que el negocio



Métricas de salud

Frescura, volumen esperado y tasa de errores: el tablero de estado de la plataforma

Un agente que responde con datos que fallaron la validación es peor que un agente que dice «no lo sé».

El lakehouse, servicio por servicio

Todo gestionado y bajo demanda: no hay clúster prendido esperando que alguien pregunte.

Servicio	Qué resuelve	Cómo se paga
 S3 + Iceberg	Las tres capas, con transacciones e historia	por GB-mes
 DMS	CDC desde producción, sin consultarla	por instancia de réplica
 Glue	Transformaciones, catálogo y reglas de calidad	por DPU-hora
 Athena	Consulta SQL sobre gold, sin infraestructura	por TB escaneado
 Lake Formation	Permisos por tabla, columna, fila y celda	sin costo adicional
 Macie	Descubre datos personales en S3	por GB analizado
 KMS	Cifrado con claves propias por dominio	por clave y request

04

Governance

Saber qué dato tenés, de dónde viene, si está bien, quién puede verlo y quién lo usó.
Eso es todo.

Governance, sin la palabra de moda

Cinco preguntas con respuesta



¿Qué tengo?

catálogo: datasets, columnas, dueño y descripción — Glue Data Catalog, SageMaker Catalog



¿De dónde viene?

linaje: el camino del dato desde el sistema origen hasta el número del dashboard



¿Está bien?

calidad: reglas, puntaje y alertas cuando algo se degrada



¿Quién puede verlo?

permisos por dominio, tabla, columna y fila — Lake Formation




¿Quién lo usó?

auditoría de accesos, incluida la del agente

Si podés responder estas cinco, tenés governance. Si no, tenés una carpeta compartida con esteroides.

El release del martes

Renombran una columna sin avisar. Nada falla a la vista — y eso es lo peor.



Cuatro días roto. Y el aviso llegó de afuera.

El mismo martes, con contrato

El mismo rename, pero ahora hay un archivo que lo frena antes de mergear

```
pedidos.contrato.yaml  
  
tabla: pedidos  
dueño: equipo-pagos  
columnas:  
  total: decimal, no_nulo  
frescura: máx 1 hora  
cambios incompatibles:  
  aviso 5 días hábiles
```



Martes 10:05 — falla el build de la app

La verificación del contrato corre en el CI del que produce: el rename no llega a mergear.



Aguas abajo no llega nada roto

Pipeline, dashboard y agente siguen leyendo total, como siempre.



Hay un dueño con nombre

equipo-pagos figura en el contrato: se sabe con quién coordinar el cambio.

Si el contrato se rompe, falla el build del que produce — no el dashboard del que consume.

Qué gana el negocio

Governance no es un costo de compliance: es velocidad



Datos firmados

Cada número tiene dueño, definición y linaje. Se puede defender frente a un auditor o un cliente.



Casos nuevos en días

El siguiente proyecto de IA reutiliza el gold que ya existe en vez de empezar de cero.



Compliance por diseño

Cuando llega la auditoría, la respuesta ya está en el catálogo. No es un proyecto de emergencia.



Una sola verdad

Se terminan las reuniones para decidir cuál de los tres números es el correcto.



Menos almacenamiento

Dejás de mantener catorce copias del mismo dataset en catorce lugares distintos.



Menos riesgo

Los datos personales están identificados y controlados antes de que un agente los lea.

05

Seguridad de datos

Que el modelo se equivoque no puede implicar que alguien vea lo que no debe ver.

Lo que el agente ve — y lo que ni le aparece

Misma tabla, mismo SELECT: el resultado depende de quién pregunta

 Consulta: agente del tenant Acme

SELECT * FROM pedidos

 PII

cliente	monto	fecha	email
Acme	\$ 184.300	03/07	...
Acme	\$ 92.150	15/07	...
Globex	\$ 47.800	21/07	...
Initech	\$ 310.900	28/07	...

Cómo leer el resultado

-  **Blanco** — lo que el rol lee
-  **Coral** — columna vedada (PII)
-  **Gris** — filas de otro tenant

 Lake Formation aplica el permiso por columna y por fila antes de que el resultado llegue al agente.

Esto no lo promete el prompt: lo aplica la plataforma en cada lectura.

IAM abre la puerta, Lake Formation decide qué se lee adentro

Dos preguntas distintas, y hace falta responder las dos



IAM — la puerta del edificio

Responde «¿este rol puede usar Athena? ¿puede tocar este bucket?». Decide a qué servicios y recursos se entra. Hasta ahí llega.



Lake Formation — las llaves de cada oficina

Una vez adentro responde «¿qué tablas, columnas y filas puede leer este rol?». Decide qué devuelve cada consulta.



acá vive lo que importa para IA

Se usan juntos: IAM sin Lake Formation deja la columna del email a un SELECT de distancia.

El agente es un usuario más

Y hay que tratarlo como tal



Rol propio

Tiene su identidad. Nunca hereda un rol de administrador ni las credenciales del usuario.



Solo gold

Sin acceso a bronze ni a silver, donde todavía viven los datos sin enmascarar.



Solo lo necesario

Si el caso de uso no necesita el documento del cliente, el rol no lo puede leer.



Filtrado por tenant

La restricción por fila se aplica en la plataforma, no depende de que el modelo se porte bien.



Consultas acotadas

Vistas y parámetros en vez de SQL libre sobre todo el esquema.



Todo auditado

Cada lectura del agente queda registrada igual que la de cualquier persona.

Datos personales y cifrado

Lo que no puede llegar nunca a la respuesta de un agente



Descubrir

Amazon Macie clasifica y detecta datos sensibles en S3: no podés proteger lo que no sabés que tenés



Clasificar

Etiquetar cada columna por sensibilidad y dejarlo registrado en el catálogo



Enmascarar en silver

Tokenizar o anonimizar en la transformación: a gold llega el dato ya tratado



Cifrar

KMS con claves propias, en reposo y en tránsito, con claves separadas por dominio



Aislar

VPC endpoints, cuentas separadas por ambiente y nada de datos productivos en desarrollo



Auditar

CloudTrail y los registros de acceso de Lake Formation: quién leyó qué y cuándo

El campo que nunca cruza de silver a gold es el campo que ningún agente va a filtrar jamás.

Residencia y soberanía de datos

Verificá la región y el alcance de los perfiles de inferencia: es lo primero que pregunta el área legal.



Dónde vive el dato

El almacenamiento y el procesamiento del lakehouse se eligen por región y quedan donde los pusiste.



Dónde se procesa el prompt

Con perfiles de inferencia entre regiones, el contenido puede procesarse en otra región del grupo. Es una decisión consciente, no un descuido.



Qué mandás al modelo

La mitigación más efectiva no es geográfica: es no enviar el dato sensible. Enmascarado en silver y recuperación acotada.



Qué exige el marco local

Regulación de datos personales y normas sectoriales. Definilo con legales antes de diseñar, no después.

Los errores que vemos seguido

Ninguno es sofisticado. Todos son caros.

Un rol para todo

El mismo rol lee producción, escribe en el lake y consulta gold. Si se filtra, se filtró todo.

Producción en desarrollo

Una copia con datos reales «para probar», en una cuenta sin los mismos controles.

El bucket con política laxa

Abierto a toda la organización porque hacía falta para una demo de hace dos años.

Credenciales en el notebook

Claves de acceso escritas en una celda, y el notebook versionado en el repositorio.

Gold que nadie definió


Cada equipo arma el suyo. Terminan tres definiciones distintas de «cliente activo».

Sin dueño

Un dataset del que dependen diez tableros y ninguna persona responsable identificada.

Del gold al agente

Cómo se conecta todo esto con la IA



No toca producción

No conoce la base transaccional.

Tampoco bronze/silver

Solo la capa ya tratada.

Permisos explícitos

Definidos en Lake Formation.

Todo registrado

Linaje y auditoría de cada lectura.

Las tres preguntas del principio ahora tienen respuesta: de dónde salió, quién puede verlo y si está bien.

Si arrancás de cero

Los primeros 90 días, en cuatro pasos

1

Días 1-15 • Inventario

Qué datos tenés, dónde están y quién los usa. Catálogo mínimo y dueños asignados. Sin esto, el resto es adivinar.

2

Días 15-45 • Un dominio

Elegí un solo dominio y hacé bronze, silver y gold completo. Uno bien terminado vale más que cinco a medias.

3

Días 45-70 • Gobierno

Reglas de calidad, linaje y permisos de grano fino sobre ese dominio. El molde para los que siguen.

4

Días 70-90 • El caso de IA

Recién ahora conectás el agente, contra gold y con rol propio. Y funciona a la primera.

El error más común es empezar por el paso cuatro y descubrir en producción que faltaban los tres anteriores.

Gracias

- El agente nunca le pega a la base productiva: le pega a gold.
- Bronze guarda, silver limpia, gold responde. Una regla por capa.
- Governance no es burocracia: son cinco preguntas con respuesta.
- La mejor protección de un dato sensible es que no llegue a gold.

Autonomía

Pasión

Confianza

Trabajo en Equipo

Innovación

Compromiso